

Université Abdelmalek Essaadi Faculté ses Sciences et techniques de Tanger Département Génie Informatique





Réalisé par: Encadré par:

- Fatima Zahrae Khayat

Pr. EL AACHAk LOTFI

- Ikram Ait-Kaddi

Remerciement:

Au terme de ce travail, nous tenons à exprimer notre profonde gratitude à notre cher professeur **Pr. EL AACHAk LOTFI** pour votre suivi et pour votre énorme soutien, qui n'a cessé de nous prodiguer et de nous guidé tout au long de ce semestre, ainsi pour votre générosité en matière de formation et d'encadrement.

Nous tenons à vous remercier monsieur de nous avoir incités à travailler en mettant à notre disposition votre expériences et votre compétence.

But de projet:



Demandez à un acheteur de maison de décrire la maison de ses rêves, et il ne commencera probablement pas par la hauteur du plafond du sous-sol ou la proximité d'une voie ferrée est-ouest. Mais l'ensemble de données de ce concours de terrain de jeu prouve que beaucoup plus influence les négociations de prix que le nombre de chambres ou une clôture blanche.

Avec 79 variables explicatives décrivant (presque) tous les aspects des maisons résidentielles à Ames, Iowa, ce projet est sert à mettre au défi de prédire le prix final de chaque maison.

PLAN

1- Introduction

2- Visualisation des données

- 1 Informations sur chaque colonne dans df_train
- 2- Le résumé statistique

3- Analyse et nettoyage des données

3-1-Caractéristiques numériques

- La matrice de corrélation
- Relation avec salePrice in train dataset
- Valeurs manguantes dans test dataset
- Vérification de la distribution de chaque caractéristique imputée avant et après l'imputation
- Feature importance
- Missing value dans Test dataset
- Normalisation des attributs

3-2- Caractéristiques catégorielles

- 3-1. Exploration et nettoyage des Categorical features
- 3-2 Affichage des valeurs nulles dans train dataset
- 3-3 Afficher les valeurs nulles dans test
- 3-4 Supprimer des colonnes avec plus de 200 valeurs nulles dans train et test dataset
- 3-5 Affichage de test et train dataset après suppression des valeurs nulles
- 3-6 Encodage

4- Joindre les caractéristiques catégorielles et les caractéristiques numériques

- Caractéristiques quasi-constantes de chute 3-1 où 70 % des valeurs sont similaires ou constantes
- 3-2 Concaténation de train et test dataset
- 3-3 Inspecter la fonction cible(target feature) (SalePrice)

5- Préparation des données pour la modélisation

6 - Modélisation

- Random forest Regressor
- Régression linéaire
- Lasso regression
- XGB Regressor
- SVR : support de régression vectorielle
- 7- Choisir le meilleur modèle
- 8- vérification de l'existence d'un sur ajustement ou d'un sous-ajustement
- 9- Submission

1- Introduction

L'apprentissage automatique est un sous-domaine de l'intelligence artificielle (IA). Leur 'objectif est de comprendre la structure des données et d'intégrer ces données dans des modèles qui peuvent être compris et utilisés par les gens.

Bien que l'apprentissage automatique soit un domaine de l'informatique, il diffère des approches informatiques traditionnelles. Dans l'informatique traditionnelle, les algorithmes sont des ensembles d'instructions explicitement programmées utilisées par les ordinateurs pour calculer ou résoudre des problèmes. Ils permettent à la place aux ordinateurs de s'entraîner sur les entrées de données et d'utiliser l'analyse statistique afin de générer des valeurs comprises dans une plage spécifique. Pour cette raison, l'apprentissage automatique facilite la création de modèles par les ordinateurs à partir d'échantillons de données afin d'automatiser les processus de prise de décision basés sur les entrées de données.


Aujourd'hui, tout utilisateur de technologie a bénéficié de l'apprentissage automatique. La technologie de reconnaissance faciale permet aux plateformes de médias sociaux d'aider les utilisateurs à marquer et à partager des photos d'amis. Les moteurs de recommandation, alimentés par l'apprentissage automatique, suggèrent les films ou les émissions de télévision à regarder ensuite en fonction des préférences de l'utilisateur. Les voitures autonomes qui s'appuient sur l'apprentissage automatique pour naviguer pourraient bientôt être disponibles pour les consommateurs......

Dans ce didacticiel, nous examinerons les méthodes d'apprentissage automatique courantes de l'apprentissage supervisé y compris la régression, El quelque modèle tel que Random forestRegressor, regression linear, Lasso Regression....

2- Exploration des données

Importation des bibliothèques nécessaires:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
from sklearn.feature_selection import VarianceThreshold
from sklearn.impute import SimpleImputer
from sklearn.feature selection import RFE
from sklearn.ensemble import ExtraTreesClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import Lasso
df_test = pd.read_csv("C:/Users/DELL/Desktop/machine_learnig/dataset/house/test.csv")
df_train = pd.read_csv("C:/Users/DELL/Desktop/machine_learnig/dataset/house/train.csv")
df_train.head()
```



Informations sur chaque colonne dans df_train

```
# info of each of the variables in our train set
df_train.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 81 columns):
# Column
               Non-Null Count Dtype
                  1460 non-null int64
0
   Id
1
    MSSubClass
                  1460 non-null
                                  int64
    MSZoning
                  1460 non-null
                                  object
    LotFrontage
                  1201 non-null
                                  float64
    LotArea
                  1460 non-null
                                 int64
5
    Street
                  1460 non-null
                                 object
    Alley
                  91 non-null
                                  object
    LotShape
                  1460 non-null
                                  object
8
    LandContour
                  1460 non-null
                                  object
    Utilities
                  1460 non-null
                                  object
10 LotConfig
                  1460 non-null
                                  object
11 LandSlope
                  1460 non-null
                                  object
12 Neighborhood 1460 non-null
                                  object
13 Condition1
                  1460 non-null
                                  object
14
    Condition2
                  1460 non-null
                                  object
15 BldgType
                  1460 non-null
                                  object
16 HouseStyle
                  1460 non-null
                                  object
17 OverallQual
                  1460 non-null
                                  int64
18 OverallCond
                  1460 non-null
                                  int64
19
    YearBuilt
                  1460 non-null
                                  int64
20 YearRemodAdd 1460 non-null
                                  int64
21 RoofStyle
                  1460 non-null
                                  object
22 RoofMatl
                  1460 non-null
                                  object
23 Exterior1st
                  1460 non-null
                                  object
24 Exterior2nd
                  1460 non-null
                                  object
25 MasVnrType
                  1452 non-null
                                  object
26 MasVnrArea
                  1452 non-null
                                  float64
27
    ExterQual
                  1460 non-null
                                  object
28
    ExterCond
                  1460 non-null
                                  object
29
    Foundation
                   1460 non-null
                                  object
 30 BsmtQual
                  1423 non-null
                                  object
31
    BsmtCond
                  1423 non-null
                                  object
```

```
32 BsmtExposure 1422 non-null object
 33 BsmtFinType1 1423 non-null object
34 BsmtFinSF1 1460 non-null int64
 35 BsmtFinType2 1422 non-null object
 36 BsmtFinSF2 1460 non-null int64
 37 BsmtUnfSF 1460 non-null int64
38 TotalBsmtSF 1460 non-null int64
 39 Heating
                        1460 non-null object
                       1460 non-null object
 40 HeatingQC
41 Centralair 1460 non-null object
42 Electrical 1459 non-null object
43 1stFlrSF 1460 non-null int64
44 2ndFlrSF 1460 non-null int64
 45 LowQualFinSF 1460 non-null int64
 46 GrLivArea
                         1460 non-null int64
47 BsmtFullBath 1460 non-null int64
48 BsmtHalfBath 1460 non-null int64
 49 FullBath 1460 non-null int64
50 HalfBath 1460 non-null int64
51 BedroomAbvGr 1460 non-null int64
52 KitchenAbvGr 1460 non-null int64
 53 KitchenQual 1460 non-null object
54 TotRmsAbvGrd 1460 non-null int64
55 Functional 1460 non-null object
56 Fireplaces 1460 non-null int64
 57 FireplaceQu 770 non-null object
58 GarageType 1379 non-null object
 59 GarageYrBlt 1379 non-null float64
 60 GarageFinish 1379 non-null object
61 GarageCars 1460 non-null int64
60 GarageCars 1460 non-nuii 1....

61 GarageArea 1460 non-null int64
 63 GarageQual 1379 non-null object
 64 GarageCond 1379 non-null object
65 PavedDrive 1460 non-null object
                         1460 non-null int64
 66 WoodDeckSF
 67 OpenPorchSF 1460 non-null int64
68 EnclosedPorch 1460 non-null int64
 69 3SsnPorch 1460 non-null int64

        70
        ScreenPorch
        1460 non-null int64

        71
        PoolArea
        1460 non-null int64

        72
        PoolQC
        7 non-null object

                                                object
                        281 non-null
                                             object
 73 Fence
 74 MiscFeature 54 non-null object
75 MiscVal 1460 non-null int64
                                                object
75 MiscVal 1460 non-null int64
                        1460 non-null int64
1460 non-null object
 77 YrSold
 78 SaleType
                                               object
 79 SaleCondition 1460 non-null
                                               object
 80 SalePrice
                        1460 non-null int64
dtypes: float64(3), int64(35), object(43)
```

```
# Drop the 'Id' column from the train set
df_train.drop(["Id"], axis=1, inplace=True)


# Save the list of 'Id' before dropping it from the test set
Id_test_list = df_test["Id"].tolist()
df_test.drop(["Id"], axis=1, inplace=True)
```

3- Analyse et nettoyage des données

3-1- Numerical features

```
# Let's select the columns of the train set with numerical data
df_train_num = df_train.select_dtypes(exclude=["object"])
```

❖ La matrice de corrélation ne considère pas les valeurs nulles



❖ Caractéristique qui ont une corrélation entre eux supérieure à 0,7

```
corr_matrix = df_train_num.corr().abs()
  #the matrix is symmetric so we need to extract upper triangle matrix without diagonal (k = 1)
  sol = (corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(np.bool))
                                 .sort_values(ascending=False))
  sol = sol.to_frame()
  sol.columns=['corr']
sol[sol['corr'] > 0.7]
C:\Users\Dell\AppData\Local\Temp/ipykernel_1820/1198977606.py:5: DeprecationWarning: `np.bool` is a deprecated alias for the bu iltin `bool`. To silence this warning, use `bool` by itself. Doing this will not modify any behavior and is safe. If you specif ically wanted the numpy scalar type, use `np.bool_` here.

Deprecated in NumPy 1.20; for more details and guidance: https://numpy.org/devdocs/release/1.20.0-notes.html#deprecations sol = (corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(np.bool))
                                             corr
  GarageCars
                         GarageArea 0.88
      YearBuilt
                         GarageYrBlt 0.83
     GrLivArea TotRmsAbvGrd 0.83
  TotalBsmtSF
                               1stFIrSF 0.82
   OverallQual
     GrLivArea
                             SalePrice 0.71
```

Nous prendrons cela en considération lors de la suppression des fonctionnalités, car si nous avons une corrélation entre les fonctionnalités de remorquage, nous devons supprimer l'une d'entre elles, nous avons donc besoin de plus d'informations pour savoir quelle est la fonctionnalité à supprimer

3-1-2 Relation avec salePrice dans train dataset


Remarque:


Les caractéristiques qui sont corrélées avec salePrice, elles nous aideront à faire la prédiction

```
# Let's select features where the correlation with 'SalePrice' is higher than |0.3|
 # -1 because the latest row is SalePrice
 df_num_corr = df_train_num.corr()["SalePrice"][:-1]
 # Correlated features (r2 > 0.5)
 high_features_list = df_num_corr[abs(
     df_num_corr) >= 0.5].sort_values(ascending=False)
 print(
     f"{len(high_features_list)} strongly correlated values with SalePrice:\n{high_features_list}\n")
 \# Correlated features (0 < r2 < 0.3)
 low\_features\_list = df\_num\_corr[(abs(df\_num\_corr) < 0.5) \& (abs(df\_num\_corr) >= 0.3)].sort\_values(ascending=False) >= 0.3) = 0.3) = 0.3
     f"{len(low_features_list)} slightly correlated values with SalePrice:\n{low_features_list}")
10 strongly correlated values with SalePrice:
GrLivArea
                0.71
GarageCars
                0.64
GarageArea
                0.62
TotalBsmtSF
               0.61
FullBath
                0.56
TotRmsAbvGrd 0.53
YearBuilt
YearBuilt 0.52
YearRemodAdd 0.51
Name: SalePrice, dtype: float64
8 slightly correlated values with SalePrice:
GarageYrBlt 0.49
MasVnrArea
              0.48
Fireplaces
              0.47
BsmtFinSE1
              0.39
LotFrontage 0.35
WoodDeckSF 0.32
2ndF1rSF
              0.32
OpenPorchSF 0.32
Name: SalePrice, dtype: float64
```

Remarque:

Nous laisserons comme valeurs numériques dans notre jeu de données celles qui ont la relation avec le prix de vente








3-1-3 Missing values dans train dataset


```
# Check the NaN of the train set by ploting percent of missing values per column
column_with_nan = df_train_num.columns[df_train_num.isnull().any()]
column_name = []
percent_nan = []
for i in column_with_nan:
   column_name.append(i)
   percent_nan.append(
       round(df_train_num[i].isnull().sum()*100/len(df_train_num), 2))
tab = pd.DataFrame(column_name, columns=["Column"])
tab["Percent_NaN"] = percent_nan
tab.sort_values(by=["Percent_NaN"], ascending=False, inplace=True)
# Define figure parameters
sns.set(rc={"figure.figsize": (10, 7)})
sns.set_style("whitegrid")
# Plot results
p.set_title("Percent of NaN per column of the train set\n", fontsize=20)
p.set_xlabel("\nPercent of NaN (%)", fontsize=20)
p.set_ylabel("Column Name\n", fontsize=20)
Text(0, 0.5, 'Column Name\n')
```




Imputation des valeurs manquantes

```
# Imputation of missing values (NaNs) with SimpleImputer
my_imputer = SimpleImputer(strategy="median")
df_train_imputed = pd.DataFrame(my_imputer.fit_transform(df_train_num))
df_train_imputed.columns = df_train_num.columns
```

3-1-4 vérification de la distribution de chaque caractéristique imputée avant et après l'imputation.



Pour "LotFrontage" et "GarageYrBlt", les distributions ont changé après imputations. Il y a une sur-représentation de la classe médiane par rapport à la distribution originale. Cependant, la distribution reste la même pour "MasVnrArea". Ainsi, pour éviter toute erreur liée à l'imputation je ne garde que la caractéristique "MasVnrArea" pour mes analyses.



3-1-5 feature importance

```
column_name = []

for i in df_train_imputed:
    column_name.append(i)
print(column_name)

array = df_train_imputed.values
X = array[:,0:15]
Y = array[:,16]


# feature extraction
model = ExtraTreesClassifier()
model.fit(X, Y)
print(model.feature_importances_)

['OverallQual', 'YearBuilt', 'YearRemodAdd', 'TotalBsmtSF', '1stFlrSF', 'GrLivArea', 'FullBath', 'TotRmsAbvGrd', 'GarageCars', 'GarageArea', 'MasVnrArea', 'BsmtFinSF1', '2ndFlrSF', 'Fireplaces', 'WoodDeckSF', 'OpenPorchSF', 'SalePrice']
[0.05545658 0.08868852 0.083371813 0.09225945 0.09207915 0.09396016
0.0201888 0.06267328 0.02767086 0.09039202 0.05746339 0.08457288
0.05056497 0.03399914 0.06631266]
```


En utilisant la méthode d'importance des caractéristiques et trouve que GrLivArea est l'attribut le plus important, après avoir 1stFlrSF et totalBsmtSF et GrageArea, nous avons déjà montré que ces attributs ont une forte corrélation avec l'attribut salePrice.

3-1-6 Missing value dans Test dataset

Les colonnes qui ont été supprimées dans la rame doivent également être supprimées dans l'ensemble de test afin que les deux ensembles de données restent identiques pour la modélisation et la prédiction.




Imputation dans test dataset



Le pourcentage de NaN dans chacune de ces caractéristiques ne dépasse pas 1,5 %. Ainsi, en imputant ces données manquantes, peu d'erreurs ont été introduites et les distributions sont similaires avant et après imputation.

6-3 Normalisation des attributs

```
scaler = StandardScaler()
 #train
 print(scaler.fit(df_train_imputed.iloc[:,0:16]))
df_train_imputed.iloc[:,0:16]=scaler.transform(df_train_imputed.iloc[:,0:16])
 # test
scaler.fit(df_test_imputed)
 print(scaler.mean_)
df_test_imputed=scaler.transform(df_test_imputed)
StandardScaler()
[6.09931507e+00 1.97126781e+03 1.98486575e+03 1.05742945e+03
1.16262671e+03 1.51546370e+03 1.56506849e+00 6.51780822e+00
1.76712329e+00 4.72980137e+02 1.03117123e+02 4.43639726e+02
3.46992466e+02 6.13013699e-01 9.42445205e+01 4.66602740e+01]
[6.07882111e+00 1.97135778e+03 1.98366278e+03 1.04607814e+03
1.15653461e+03 1.48604592e+03 1.57093900e+00 6.38519534e+00
1.76627827e+00 4.72773818e+02 9.96737491e+01 4.39142906e+02
3.25967786e+02 5.81220014e-01 9.31747772e+01 4.83139136e+01]
```



3-2- Categorical features

3-2-1 Exploration et nettoyage des Categorical features

```
: cat =[
    i for i in df_train.columns if df_train.dtypes[i] == "object"]
# test dataset
df_test_cat = df_test[cat]
# train dataset

df_train_cat = df_train[cat]
df_train_cat.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 43 columns):
                              Non-Null Count Dtype
       Column
       MSZoning 1460 non-null object
Street 1460 non-null object
Alley 91 non-null object
LotShape 1460 non-null object
LandContour 1460 non-null object
 0
 1
 2
 3
       Utilities 1460 non-null object
LotConfig 1460 non-null object
LandSlope 1460 non-null object
 5
  6
 7
  8 Neighborhood 1460 non-null object
        Condition1 1460 non-null object
Condition2 1460 non-null object
  9
 10 Condition2
 10 Condition2 1400 non-null object
11 BldgType 1460 non-null object
12 HouseStyle 1460 non-null object
13 RoofStyle 1460 non-null object
14 RoofMatl 1460 non-null object
 14 RoofMatl 1460 non-null object
15 Exterior1st 1460 non-null object
16 Exterior2nd 1460 non-null object
17 MasVnrType 1452 non-null object
18 ExterQual 1460 non-null object
19 ExterCond 1460 non-null object
20 Foundation 1460 non-null object
21 BsmtQual 1423 non-null object
22 BsmtCond 1423 non-null object
23 BsmtCond 1423 non-null object
 23 BsmtExposure 1422 non-null object
24 BsmtFinType1 1423 non-null object
25 BsmtFinType2 1422 non-null object
26 Heating 1460 non-null object
27 HeatingQC 1460 non-null object
28 CentralAir 1460 non-null object
29 Electrical 1459 non-null object
  30 KitchenQual 1460 non-null object
                                   1460 non-null object
  31 Functional
  32 FireplaceQu
                                     1379 non-null object
  33 GarageType
  34 GarageFinish 1379 non-null object
 35 GarageQual 1379 non-null object
36 GarageCond 1379 non-null object
37 PavedDrive 1460 non-null object
 38 PoolQC 7 non-null
39 Fence 281 non-null
40 MiscFeature 54 non-null
                                                                     object
                                                                     object
                                                                      object
 41 SaleType
                                     1460 non-null object
 42 SaleCondition 1460 non-null object
dtypes: object(43)
memory usage: 490.6+ KB
```

Affichage des valeurs des features :

```
s = []
i = 0
for k in df_train_cat.select_dtypes(include=["object"]):
    print(k, df_train_cat[k].unique())

s.append(df_train_cat[k].unique())
for j in s:
    for m in j:
        # print(m)

s=[]
#d = {1: 'red', 2: 'orange', 3: 'yellow'}
#lst = [d[k] for k in lst]
```


```
MSZoning ['RL' 'RM' 'C (all)' 'FV' 'RH']
  Street ['Pave' 'Grv1']
   Alley [nan 'Grvl' 'Pave']
  LotShape ['Reg' 'IR1' 'IR2' 'IR3']
LandContour ['Lv1' 'Bnk' 'Low' 'HL
Utilities ['AllPub' 'NoSeWa']
                                                                                  'Low' 'HLS'1
  Cottonfig ['Inside' 'FR2' 'Corner' 'CulDSac' 'FR3']
LandSlope ['Gt1' 'Mod' 'Sev']
Neighborhood ['CollgCr' 'Veenker' 'Crawfor' 'NoRidge' 'Mitchel' 'Somerst' 'NWAmes'
 Neighborhood ['CollgCr' 'Veenker' 'Crawfor' 'NoRidge' 'Mitchel' 'Somerst' 'NWAm
'OldTown' 'BrkSide' 'Sawyer' 'NridgHt' 'NAmes' 'SawyerW' 'IDOTRR'
'MeadowV' 'Edwards' 'Timber' 'Gilbert' 'StoneBr' 'ClearCr' 'NPkVill'
'Blmmgtn' 'BrDale' 'SWISU' 'Blueste']
Condition1 ['Norm' 'Feedr' 'PosN' 'Artery' 'RRAe' 'RRNn' 'RRAn' 'PosA' 'RRNe']
Condition2 ['Norm' 'Artery' 'RRNn' 'Feedr' 'PosN' 'PosA' 'RRAn' 'RRAe']
BldgType ['1Fam' '2fmCon' 'Duplex' 'TwnhsE' 'Twnhs']
  HouseStyle ['25tory' '15tory' '1.5Fin' '1.5Unf' 'SFoyer' 'SLvl' '2.5Unf' '2.5Fin']
RoofStyle ['Gable' 'Hip' 'Gambrel' 'Mansard' 'Flat' 'Shed']
RoofMatl ['CompShg' 'WdShngl' 'Metal' 'WdShake' 'Membran' 'Tar&Grv' 'Roll'
      'ClvTile'l
  Exterior1st ['Viny1Sd' 'MetalSd' 'Wd Sdng' 'HdBoard' 'BrkFace' 'WdShing' 'CemntBd'
      'Plywood' 'AsbShng' 'Stucco' 'BrkComm' 'AsphShn' 'Stone' 'ImStucc
  Exterior2nd ['Viny1Sd' 'MetalSd' 'Wd Shng' 'HdBoard' 'Plywood' 'Wd Sdng' 'CmentBd' 
'BrkFace' 'Stucco' 'AsbShng' 'Brk Cmn' 'ImStucc' 'AsphShn' 'Stone'
    'Other' 'CBlock']
  MasVnrType ['BrkFace' 'None' 'Stone' 'BrkCmn' nan]
ExterQual ['Gd' 'TA' 'Ex' 'Fa']
ExterCond ['TA' 'Gd' 'Fa' 'Po' 'Ex']
Foundation ['PConc' 'CBlock' 'BrkTil' 'Wood' 'Slab' 'Stone']
ExterCond ['TA' 'Gd' 'Fa' 'Po' 'Ex']
Foundation ['PConc' 'CBlock' 'BrkTil' 'Wood' 'Slab' 'Stone']
BsmtQual ['Gd' 'TA' 'Ex' nan 'Fa']
BsmtCond ['TA' 'Gd' nan 'Fa' 'Po']
BsmtExposure ['No' 'Gd' 'Mn' 'Av' nan]
BsmtFinType1 ['GLQ' 'ALQ' 'Unf' 'Rec' 'BLQ' nan 'LwQ']
BsmtFinType2 ['Unf' 'BLQ' nan 'ALQ' 'Rec' 'LwQ' 'GLQ']
Heating ['GasA' 'GasW' 'Grav' 'Wall' 'OthW' 'Floor']
HeatingC ['Ex' 'Gd' 'TA' 'Fa' 'Po']
CentralAir ['Y' 'N']
Electrical ['Sbrkn' 'FuseF' 'FuseA' 'FuseP' 'Mix' nan]
KitchenQual ['Gd' 'TA' 'Ex' 'Fa']
Functional ['Typ' 'Min1' 'Maj1' 'Min2' 'Mod' 'Maj2' 'Sev']
FireplaceQu [nan 'TA' 'Gd' 'Fa' 'Ex' 'Po']
GarageType ['Attchd' 'Detchd' 'BuiltIn' 'CarPort' nan 'Basment' '2Types']
GarageQual ['TA' 'Fa' 'Gd' nan 'Ex' 'Po']
GarageQond ['TA' 'Fa' 'Gd' nan 'Ex' 'Po']
GarageCond ['TA' 'Fa' 'Gd' 'Po' 'Ex']
PavedDrive ['Y' 'N' 'P']
PoolQC [nan 'Ex' 'Fa' 'Gd']
Fence [nan 'MnPrv' 'GdWo' 'GdPrv' 'MnWw']
MiscFeature [nan 'Shed' 'Gar2' 'Othr' 'TenC']
  MiscFeature [nan 'Shed' 'Gar2' 'Othr' 'TenC']
SaleType ['WD' 'New' 'COD' 'ConLD' 'ConLI' 'CWD' 'ConLw' 'Con' 'Oth']
SaleCondition ['Normal' 'Abnorm1' 'Partial' 'AdjLand' 'Alloca' 'Family']
```

```
for k in df_train_cat:
      print(df_train_cat[k].value_counts())
RL
RM
FV
               218
                65
RH 16
C (all) 10
Name: MSZoning, dtype: int64
Pave 1454
Grv1 6
Name: Street, dtype: int64
Grvl 50
Pave 41
Name: Alley, dtype: int64
Reg
IR1
         925
         484
IR2
IR3
          41
          10
Name: LotShape, dtype: int64
Lvl
        1311
Bnk
           63
```

3-2-2 Affichage des valeurs nulles dans train dataset

```
null_list = []
for col in df_train_cat.columns:
    null = df_train_cat[col].isnull().sum()
    if null != 0:
        null_list.append([col,null])
null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df = pd.DataFrame(null_dist,columns=['Feature','Null'])
null_df :set_index('Feature')
null_df['Total Null'] = null_df['Null']
print("Total columns with null:")
print("Total columns with null:")
print(mull_df)
print("Total null values:")
print(null_df)
print("Iotal Null'].sum(axis=0))
sns.set_palette(sns.color_palette("tab10"))
sns.barplot(data=null_df.sort_values(by='Total Null',ascending = False).head(19), x='Feature',y='Total Null')
plt.xticks(rotation = 70)
plt.title("Total Nulls in Feature dataset train")
plt.show()


Total columns with null:
16
Total null values:
6617
```



3-2-3 Affichage des valeurs nulles dans test dataset

```
null_list = []
for col in df_test_cat.columns:
    null = df_test_cat[col].isnull().sum()
    if null! = 0:
        null_list.append([col,null])
null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df.set_index('Feature')
null_df['Total Null'] = null_df['Null']
print("Total columns with null:")
print("Total columns with null:")
print("Total null values:")
print(null_df['Total Null'].sum(axis=0))
sns.set_palette(sns.color_palette("tabl0"))
sns.set_poll(ddata=null_df.sort_values(by='Total Null',ascending = False).head(19), x='Feature',y='Total Null')
plt.xticks(rotation = 70)
plt.title("Total Nulls in Feature dataset test")
plt.show()

Total columns with null:
22
Total null values:
6670
```



3-2-4 Suppression des colonnes contenant plus de 200 valeurs nulles dans train et test dataset

```
col_with_null=[]
for col in df_train_cat.columns:
    if df_train_cat[col].isnull().sum()> 150:
        col_with_null.append(col)
        df_train_cat.drop([col], axis = 1, inplace = True)
        df_test_cat.drop([col], axis = 1, inplace = True)


C:\Users\Dell\anaconda3\lib\site-packages\pandas\core\frame.py:4906: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
    return super().drop(
```

3-2- 5 Affichage de test et train dataset après la suppression des nuls


```
inull_list = []
for col in df_test_cat.columns:
    null = df_test_cat[col].isnull().sum()
    if null != 0:
        null_list.append([col,null])
null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df.set_index('Feature')
null_df['Total Null'] = null_df['Null']
print("Total columns with null:")
print("Total columns with null:")
print(null_df))
print("Total null values:")
print(null_df)'
print("Total Null'].sum(axis=0))
sns.set_palette(sns.color_palette("tabl0"))
sns.barplot(data=null_df.sort_values(by='Total Null',ascending = False).head(19), x='Feature',y='Total Null')
plt.xticks(rotation = 70)
plt.title("Total Nulls in Feature dataset test")
plt.show()

Total columns with null:
17
Total null values:
555
```



```
null_list = []
for col in df_train_cat.columns:
    null = df_train_cat[col].isnull().sum()
    if null != 0:
        null_list.append([col,null])
null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df.set_index('Feature')
null_df['Total Null'] = null_df['Null']
print("Total columns with null:")
print("Total columns with null:")
print(len(null_df))
print("Total null values:")
print(null_df['Total Null'].sum(axis=0))
sns.set_palette(sns.color_palette("tab10"))
sns.barplot(data=null_df.sort_values(by='Total Null',ascending = False).head(19), x='Feature',y='Total Null')
plt.xticks(rotation = 70)
plt.title("Total Nulls in Feature dataset train")
plt.show()

Total columns with null:
11
Total null values:
520
```



Imputation des valeurs manquantes in test and train dataset

```
# Imputation of missing values (NaNs) with SimpleImputer
  my_imputer = SimpleImputer(strategy="most_frequent")
  df_train_imputed_cat = pd.DataFrame(my_imputer.fit_transform(df_train_cat))
  df_train_imputed_cat.columns = df_train_cat.columns
 df_test_imputed_cat = pd.DataFrame(my_imputer.fit_transform(df_test_cat))
df_test_imputed_cat.columns = df_test_cat.columns
 for k in df_train_imputed_cat:
    print(df_train_imputed_cat[k].value_counts())
                65
RH 16
C (all) 10
Name: MSZoning, dtype: int64
Pave
Grv1
         1454
             6
Name: Street, dtype: int64
Reg 925
IR1 484
IR2 41
IR3 10
Name: LotShape, dtype: int64
Bnk
HLS
           50
           36
Name: LandContour, dtype: int64
```

Après nettoyage:

```
# train
null_list = []

for col in df_train_imputed_cat.columns:
    null = df_train_imputed_cat[col].isnull().sum()
    if null! = 0:
        null_list.append([col,null])

null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df.set_index('Feature')
null_df['Total Null'] = null_df['Null']

print("Total columns with null:")
print(print("Total null values:")
print(null_df['Total Null'].sum(axis=0))
print("Total columns:")
df_train_imputed_cat.shape

Total columns with null:
0
Total columns with null:
0
Total columns with null:
0
Total columns:
(1460, 38)
```

```
# test|
null_list = []


for col in df_test_imputed_cat.columns:
    null = df_test_imputed_cat[col].isnull().sum()
    if null != 0:
        null_list.append([col,null])

null_df = pd.DataFrame(null_list,columns=['Feature','Null'])
null_df.set_index('Feature')
null_df.set_index('Feature')
null_df['Total Null'] = null_df['Null']

print("Total columns with null:")
print(#Total null values:")
print(null_df['Total Null'].sum(axis=0))
print("Total columns:")
df_test_imputed_cat.shape

Total columns with null:
0
Total columns with null:
10
Total columns:
10
Total columns:
11
Total columns:
12
Total columns:
13
Total columns:
14
Total columns:
15
Total columns:
16
Total columns:
17
Total columns:
18
Total columns:
19
Total columns:
19
Total columns:
19
Total columns:
19
Total columns:
10
Total columns:
10
Total columns:
10
Total columns:
11
Total columns:
12
Total columns:
13
Total columns:
14
Total columns:
15
Total columns:
16
Total columns:
17
Total columns:
17
Total columns:
18
Total columns:
19
Total c
```

3-2- 6 encodage :



4- Concatenation des categorical features et numreical features

```
# Add binary features to numreical features
# Train set
df_train_new = df_train_imputed.join(df_train_imputed_cat)
print(f"Train set: {df_train_new.shape}")

# Test set
df_test_new = pd.DataFrame(df_test_imputed).join(df_test_imputed_cat)
print(f"Test set: {df_test_new.shape}")


Train set: (1460, 55)
Test set: (1459, 54)
```


4-1 suppression des caractéristiques quasiconstantes où 70 % des valeurs sont similaires ou constantes



Après la suppression :

```
sns.set_theme()
fig=plt.figure(figsize=(20,40))
for i in range(len((df_train_new.select_dtypes(include='int')).columns)):
    fig.add_subplot(11,4,i+1)
    df_train_new.select_dtypes(include='int').iloc[:,i].value_counts().plot(kind="pie", subplots=True)
```







4-2 concatenation de training dataset et test dataset

```
data = pd.concat([df_train_new,df_test_new])
data.isnull().sum().sum()
48163
```

4-3-Inspecter la fonction cible (SalePrice)



Nous pouvons voir que la distribution de la variable cible est biaisée. De nombreux modèles linéaires supposent que les données sont normalement distribuées. Une distribution asymétrique rendrait également difficile l'interprétation des coefficients du modèle. Et cela conduit souvent à des problèmes tels que le sur ajustement. Pour éviter de tels problèmes plus tard dans le processus, nous distribuerons normalement notre variable cible.



NOTE:

Nous devrions appliquer expo après la modélisation. La distribution de l'entité cible semble normale maintenant. Nous sommes donc bons pour aller plus loin.

5- Préparation des données pour la modélisation

```
# Extract the features (X) and the target (y)
 # Features (X)
 X = df_train_new[[i for i in list(
    df_train_new.columns) if i != "SalePrice"]]
 print(X.shape)
 # Target (y)
 y = df_train_new.loc[:, "SalePrice"]
 print(y.shape)
print(y)
(1460, 46)
(1460,)
1
       12.11
       12.32
       11.85
       12.43
1455 12.07
1456 12.25
1457 12.49
1458 11.86
1459 11.90
Name: SalePrice, Length: 1460, dtype: float64
```

```
# split data to test and train
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, shuffle=True)
print(f"X_train:{X_train.shape}\ny_train:{y_train.shape}")
print(f"\nX_test:{X_test.shape}\ny_test:{y_test.shape}")

X_train:(1168, 46)
y_train:(1168,)

X_test:(292, 46)
y_test:(292,)

# list ereur and score and algorithm
model_list = []
MAE_list = []
MSE_list = []
RMSE_list = []
RMSE_list = []
r2_score_list = []
```

6- Modélisation

6.1 Random forestRegressor

random forest regressor est un méta estimateur qui ajuste un certain nombre d'arbres de décision de classification sur divers sous-échantillons de l'ensemble de données et utilise la moyenne pour améliorer la précision prédictive et contrôler le surajustement. La taille du sous-échantillon est contrôlée avec le paramètre <u>max samples</u> si bootstrap=True (par défaut), sinon l'ensemble de données entier est utilisé pour construire chaque arbre.

```
RandomForest = RandomForestRegressor(n_estimators = 400,min_samples_split = 2,min_samples_leaf = 1,max_features= 'sqrt',max_dept model_list.append(RandomForest._class_.__name_)
RandomForest.fit(X_train, y_train)
predictions = RandomForest.predict(X_test)
#predictions


# predictions.shape

(292,)

y_test.shape

(292,)
```

❖ Score de Random forestRegressor



```
from sklearn import metrics

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, predictions))

print('Mean Squared Error:', metrics.mean_squared_error(y_test, predictions))

print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, predictions)))

MAE_list.append(metrics.mean_absolute_error(y_test, predictions))

MSE_list.append(metrics.mean_squared_error(y_test, predictions))

RMSE_list.append(np.sqrt(metrics.mean_squared_error(y_test, predictions)))

Mean Absolute Error: 0.09231568918824558

Mean Squared Error: 0.02278195654054397

Root Mean Squared Error: 0.1441594830059541
```

```
df = pd.DataFrame({'Actual': y_test, 'Predicted': predictions})
df.head(10)
    Actual Predicted
423 12.66
1407 11.63
360 11.96
              11.88
837 11.51
393 11.51
              11.37
679 11.76
             11.83
611 11.90
              11.94
964 12.28
             12.30
 36 11.88
             11.91
```

6.2 Regression linear:

La régression linéaire simple est un type d'analyse de régression où le nombre de variables indépendantes est égal à un et il existe une relation linéaire entre la variable indépendante (x) et dépendante (y). La ligne rouge dans le graphique ci-dessus est appelée la ligne droite la mieux ajustée. Sur la base des points de données donnés, nous essayons de tracer une ligne qui modélise le mieux les points. La ligne peut être modélisée sur la base de l'équation linéaire ci-dessous.

<u>Équation linéaire</u>

$$y = a_0 + a_1 * x$$

Le motif de l'algorithme de régression linéaire est de trouver les meilleures valeurs pour a_0 et a_1. Avant de passer à l'algorithme, examinons deux concepts importants que vous devez connaître pour mieux comprendre la régression linéaire

```
# regressor = LinearRegression()
model_list.append(regressor._class_.__name__)
regressor.fit(X_train, y_train) #training the algorithm
#To retrieve the intercept:
print(regressor.intercept_)
#For retrieving the slope:
print(regressor.coef_)


11.996745389933391
[ 0.11480177   0.03096827   0.04469467   0.00492103   0.03311564   0.06018292
   0.00180406   0.02721568   0.05350393   0.00386185   -0.00064147   0.01063139
   0.02547697   0.03432148   0.01195278   -0.0099994   -0.01818628   -0.00972817
   0.00744759   -0.00106573   0.0008087   -0.00081958   -0.02450919   -0.00961695
   0.00889738   0.02691349   -0.00548264   0.00244195   -0.00399359   0.0144347
   0.00115621   0.00144539   -0.01915319   0.01495445   -0.01526198   -0.01648871
   -0.00904066   -0.00951113   0.00533332   -0.02085203   0.0222642   -0.00522324
   -0.00136287   0.01541592   -0.00175661   0.02126839]
```

```
#prediction
y_pred = regressor.predict(X_test)|
```

Score de Regresssion linear :

```
# score
print("R2 score", r2_score(y_test, y_pred))
r2_score_list.append(r2_score(y_test, y_pred))
R2 score 0.8495998475676023
```

```
df = pd.DataFrame({'Actual': y_test, 'Predicted': y_pred})
df.head(20)
    Actual Predicted
423 12.66
             12.59
1407 11.63
             11.73
360 11.96 11.98
837 11.51
             11.61
           11.32
393 11.51
1199 11.90
             11.82
679 11.76 11.71
 611 11.90
             12.03
964 12.28 12.31
 36 11.88
             11.89
602 12.30
             12.36
301 12.50
             12.51
439 11.61 11.84
1081 11.80
             11.75
172 12.38 12.11
252 12.06
             12.08
559 12.36 12.16
796 11.87
             11.99
788 11.59 11.50
118 12.68
             12.81
```



```
: # Error

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_pred))
print('Mean Squared Error:', metrics.mean_squared_error(y_test, y_pred))
print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

MAE_list.append(metrics.mean_absolute_error(y_test, y_pred))|
MSE_list.append(metrics.mean_squared_error(y_test, y_pred)))

RMSE_list.append(np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

Mean Absolute Error: 0.104831945588886867

Mean Squared Error: 0.0230571917185756

Root Mean Squared Error: 0.1518459473235147
```

6-3- Lasso Regression

La régression au lasso est une technique de régularisation. Il est utilisé sur les méthodes de régression pour une prédiction plus précise. Ce modèle utilise le retrait. Le rétrécissement est l'endroit où les valeurs des données sont rétrécies vers un point central comme moyenne. La procédure de lasso encourage les modèles simples et clairsemés (c'est-à-dire les modèles avec moins de paramètres). Ce type particulier de régression est bien adapté aux modèles présentant des niveaux élevés de multi colinéarité ou lorsque vous souhaitez automatiser certaines parties de la sélection du modèle, comme la sélection de variables/l'élimination de paramètres.


```
#Lasso Regression

#Initializing the Lasso Regressor
lasso_reg = Lasso(alpha=0.001)
model_list.append(lasso_reg.__class__.__name__)
#Fitting the Training data to the Lasso regressor
lasso_reg.fit(X_train,y_train)
#Predicting for X_test
y_pred_lass = lasso_reg.predict(X_test)
```

Score de lasso Regressor

```
print("R2 score", r2_score(y_test, y_pred_lass))
r2_score_list.append(r2_score(y_test, y_pred_lass))
R2 score 0.8509778938626734
```

```
df = pd.DataFrame({'Actual': y_test, 'Predicted': y_pred_lass})
df.head(10)
     Actual Predicted
423
      12.66
                 12.60
1407
      11.63
                 11.73
360
      11.96
                 11.98
 837
      11.51
                 11.62
393
      11.51
                 11.33
1199
      11.90
                 11.82
      11.76
                 11.71
 611
      11.90
                 12.03
964
      12.28
                 12.31
                 11.89
 36
      11.88
```



```
# error

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_pred_lass))

print('Mean Squared Error:', metrics.mean_squared_error(y_test, y_pred_lass))

print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, y_pred_lass)))

MAE_list.append(metrics.mean_absolute_error(y_test, y_pred_lass))

MSE_list.append(metrics.mean_squared_error(y_test, y_pred_lass))

RMSE_list.append(np.sqrt(metrics.mean_squared_error(y_test, y_pred_lass)))

Mean Absolute Error: 0.10454065522312181

Mean Squared Error: 0.022845929448500384

Root Mean Squared Error: 0.1511486997909687
```

6-4- XGB Regressor

```
#XGB
xgbr = xgb.XGBRegressor()|
model_list.append(xgbr.__class__.__name__)
xgbr.fit(X_train, y_train)
#Predicting for X_test
predict_xgb = xgbr.predict(X_test)
```


Score de XGB Regressor

```
print("R2 score", r2_score(y_test, predict_xgb))
r2_score_list.append(r2_score(y_test,predict_xgb))
R2 score 0.860995958787952
```

```
#error
print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, predict_xgb))
print('Mean Squared Error:', metrics.mean_squared_error(y_test, predict_xgb))
print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, predict_xgb)))
MAE_list.append(metrics.mean_absolute_error(y_test, predict_xgb))
MSE_list.append(metrics.mean_squared_error(y_test, predict_xgb))
RMSE_list.append(np.sqrt(metrics.mean_squared_error(y_test, predict_xgb)))
Mean Absolute Error: 0.09801434425068288
Mean Squared Error: 0.021310103587319083
Root Mean Squared Error: 0.1459798054092383
```

```
df = pd.DataFrame({'Actual': y_test, 'Predicted': predict_xgb})
df.head(10)
    Actual Predicted
423 12.66 12.75
360 11.96
             11.93
837 11.51
              11.45
393 11.51
              11.38
1199
679 11.76
             11.84
611 11.90
             11.89
964 12.28 12.26
```

6-5- SVR: Support Vector Regression



SVR a été initialement proposé par Drucker et al., qui est une technique d'apprentissage supervisé, basée sur le concept des vecteurs de support de Vapnik. Le SVR vise à réduire l'erreur en déterminant l'hyperplan et en minimisant l'écart entre les valeurs prédites et observées. La minimisation de la valeur de w dans l'équation ci-dessous est similaire à la valeur définie pour maximiser la marge, comme illustré à la Fig. 1

```
regressor = SVR(kernel = 'rbf')
model_list.append(regressor._class_.__name__)
regressor.fit(X_train, y_train)

SVR()

predict_SVR = regressor.predict(X_test)
```

❖ Score de SVR

```
print("R2 score", r2_score(y_test, predict_SVR))
r2_score_list.append(r2_score(y_test, predict_SVR))|


R2 score 0.8613427519811511

print('Mean Absolute Error:', metrics.mean_absolute_error(y_test, predict_SVR))
print('Mean Squared Error:', metrics.mean_squared_error(y_test, predict_SVR))
print('Root Mean Squared Error:', np.sqrt(metrics.mean_squared_error(y_test, predict_SVR)))

MAE_list.append(metrics.mean_absolute_error(y_test, predict_SVR))
MSE_list.append(metrics.mean_squared_error(y_test, predict_SVR)))

Mean Absolute Error: 0.09494086148692205
Mean Squared Error: 0.021256938234671702
Root Mean Squared Error: 0.14579759337750298
```

```
df = pd.DataFrame({'Actual': y_test, 'Predicted': predict_SVR})
df.head(10)
     Actual Predicted
423 12.66
               12.68
1407 11.63
                11.67
 360 11.96
               11.95
      11.51
               11.54
 837
393 11.51
               11.40
1199
      11.90
               11.81
             11.74
 679 11.76
 611
      11.90
                11.98
 964 12.28
               12.29
 36 11.88
                11.89
```



```
RMSE_list
[0.1441594830059541,
0.1518459473235147,
0.1511486997909687,
0.1459798054092383.
0.14579759337750298]
MSE_list
r0.02078195654054397,
0.0230571917185756,
0.022845929448500384,
0.021310103587319083,
0.021256938234671702]
model_list
['RandomForestRegressor', 'LinearRegression', 'Lasso', 'XGBRegressor', 'SVR']
MAE list
[0.09231568918824558,
0.10483194558888667,
0.10454065522312181,
0.09801434425068288,
0.09494086148692205]
r2_score_list
[0.8644410182432066,
0.8495998475676023,
0.8509778938626734,
0.860995958787952,
0.8613427519811511]
```

7- choix du meilleur model


```
# Create a table with pd.DataFrame for all results
model_results = pd.DataFrame({"Model": model_list,
                           "MAE": MAE_list,
                          "MSE": MSE_list,
                          "RMSE": RMSE_list,
                          "R2_score":r2_score_list})
model_results
              Model MAE MSE RMSE R2_score
0 RandomForestRegressor 0.09 0.02 0.14
  LinearRegression 0.10 0.02 0.15
1
                                     0.85
     Lasso 0.10 0.02 0.15 0.85
2
   XGBRegressor 0.10 0.02 0.15
3
                                    0.86
    SVR 0.09 0.02 0.15 0.86
```


Remarque:

Nous choisirons SVR car l'erreur est petite et R2_score est le plus grand

8- Verification de l'existance de overfiting ou underfiting:

```
def ModelLearning(X, v):
       Calculates the performance of several models with varying sizes of training descriptions of training descriptions.
        The learning and testing scores for each model are then plotted. ""
   # Create 10 cross-validation sets for training and testing
   cv = ShuffleSplit(n_splits = 10, test_size = 0.2, random_state = 0)
    # Generate the training set sizes increasing by 50
   train_sizes = np.rint(np.linspace(1, X.shape[0]*0.8 - 1, 9)).astype(int)
   # Create the figure window
   fig = plt.figure(figsize=(10,7))
   # Create three different models based on max depth
   for k, depth in enumerate([1,3,6,10]):
        # Create a DecisionTreeRegressor
        regressor = DecisionTreeRegressor(max_depth = depth)
        # Calculate the training and testing scores
        sizes, train_scores, test_scores = learning_curve(regressor, X, y, \
            cv = cv, train_sizes = train_sizes, scoring = 'r2')
        # Find the mean and standard deviation for smoothing
        train_std = np.std(train_scores, axis = 1)
        train_mean = np.mean(train_scores, axis = 1)
        test_std = np.std(test_scores, axis = 1)
        test_mean = np.mean(test_scores, axis = 1)
        # Subplot the learning curve
        ax = fig.add_subplot(2, 2, k+1)
        ax.plot(sizes, train_mean, 'o-', color = 'r', label = 'Training Score')
ax.plot(sizes, test_mean, 'o-', color = 'g', label = 'Testing Score')
        ax.fill_between(sizes, train_mean - train_std, \
            train_mean + train_std, alpha = 0.15, color = 'r')
        ax.fill_between(sizes, test_mean - test_std,
            test_mean + test_std, alpha = 0.15, color = 'g')
        ax.set_title('max_depth = %s'%(depth))
        ax.set_xlabel('Number of Training Points')
        ax.set_ylabel('Score')
        ax.set_xlim([0, X.shape[0]*0.8])
        ax.set_ylim([-0.05, 1.05])
    # Visual aesthetics
    ax.legend(bbox_to_anchor=(1.05, 2.05), loc='lower left', borderaxespad = 0.)
    fig.suptitle('Decision Tree Regressor Learning Performances', fontsize = 16, y = 1.03)
    fig.tight_layout()
    fig.show()
```





Remarque:

On Remarque qu'il n'y a pas de overfitting ou d'underfitting

9- Soumission

```
: predict_SVR.shape
(292,)
: len(Id_test_list)
1459
: df_test_new.shape
(1459, 46)
```

❖ Application de l'expo au SalePrice

```
#predict = regressor.predict(X_test)
# predict
# We take antilog i.e. np.exp to convert log predictions to actual prices.
predict = np.exp(regressor.predict(df_test_new))
#predict=scaler.inverse_transform(regressor.predict(X_test))
#print(regressor.predict(X_test))
submission = pd.DataFrame({"Id": Id_test_list,
                        "SalePrice": predict})
submission.head(10)
    ld SalePrice
0 1461 115,493.26
1 1482 159,113.23
2 1463 182,040.07
3 1464 190,585.02
4 1465 178,832.31
5 1466 176,567.82
6 1487 171,402.04
7 1468 166,193.59
8 1469 185,930.30
9 1470 119,419.45
```

```
import joblib

submission.to_csv("submission.csv", index=False)

file = 'model.sav'
joblib.dump(regressor, file)

['model.sav']
```

References:

- https://medium.com/analytics-vidhya/support-vector-regression-svr-model-a-regression-based-machine-learning-approach-f4641670c5bb
- https://www.kaggle.com/c/house-prices-advanced-regression-techniques

•